



UNIVERSIDADE ESTADUAL DE CAMPINAS -  
UNICAMP

Faculdade de Tecnologia - FT

Doutorado em Tecnologia

### Projeto de Pesquisa

## Estudo da Viabilidade da Utilização de Visão Computacional

### Empregada à Identificação de Variedades de Cana-de-açúcar

Julio Cesar de Lemos

Orientador: Prof. Dr. André F. de

Angelis

Limeira - SP

SP2023



## 1. Objetivos

O objetivo deste trabalho é avaliar a aplicabilidade da visão computacional no contexto agrícola, visando otimizar o processo de identificação das variedades de cana-de-açúcar.

São objetivos específicos:

- Realizar uma revisão de literatura científica para identificar os algoritmos de visão computacional mais utilizados e com melhores resultados em reconhecimento de espécies de plantas, considerando critérios como acurácia, velocidade de processamento, eficiência computacional e facilidade de implementação.
- Desenvolver uma base de dados de imagens de cana-de-açúcar representativas das duas variedades de cana, contemplando uma diversidade de imagens de alta qualidade, diferentes ângulos de captura, condições de iluminação e variações nas características das plantas.
- Realizar experimentos controlados utilizando a base de dados de imagens de cana-de-açúcar, treinando e testando os algoritmos de visão computacional selecionados. Avaliar a acurácia e a eficiência dos algoritmos em relação à identificação das variedades de cana-de-açúcar.
- Desenvolver uma avaliação comparativa dos resultados obtidos pelos algoritmos de visão computacional com as informações fornecidas por especialistas agrícolas, validando a eficácia da visão computacional no contexto agrícola específico da identificação de variedades de cana-de-açúcar.
- Fornecer recomendações para aprimorar e otimizar o uso da visão computacional nessa aplicação específica, visando contribuir para o avanço do conhecimento científico e tecnológico na agricultura.

## 2. Introdução e Revisão de Literatura

(VC)

A Inteligência Artificial (IA) tem se estabelecido como uma revolucionária disciplina que desempenha um papel crucial em diversos setores, inclusive na agricultura. Uma das capacidades mais notáveis da IA é a habilidade de processar imagens para o reconhecimento de padrões. Esta vertente da IA, a Visão Computacional, dedica-se ao desenvolvimento de algoritmos e técnicas que permitem aos computadores entenderem e interpretarem informações visuais do mundo real com notável precisão. Isso possibilita que as máquinas reconheçam objetos, padrões e características em imagens e vídeos com notável precisão. Na agricultura, a Visão Computacional tem sido amplamente aplicada para identificar e analisar aspectos relevantes, como prever a produtividade da cana-de-açúcar em diferentes ambientes de produção (ALMEIDA et al., 2021) reconhecimento de doenças em folhas de cana (MILITANTE; GERARDO; MEDINA, 2019); (ORDINE PIRES DA SILVA SIMÕES et al., 2023); (ORDINE PIRES DA SILVA SIMÕES et al., 2023) ; (MILITANTE; GERARDO; DIONISIO, 2019); (HEMALATHA et al., 2022); (KUMPALA; WICHAPHA; PRASOMSAB, 2022) e identificação de espécies de plantas (BONNET et al., 2016); (ZHAO et al., 2015); (WÄLDCHEN et al., 2018).

No contexto de identificação de plantas, pesquisas recentes apontam para a crescente utilização da Visão Computacional como uma abordagem inovadora e eficaz utilizada em contra-ponto ao processo de identificação manual, realizado por especialistas humanos. Tais especialistas, como botânicos e taxonomistas, possuem amplo conhecimento e experiência para reconhecer diferenças sutis entre as espécies de plantas, tendo como base suas características morfológicas. No entanto, tal abordagem possui algumas desvantagens, como por exemplo a limitação de escala, e ao número limitado de profissionais qualificados e a subjetividade inerente à interpretação humana (BONNET et al., 2016). Combinando técnicas de processamento de imagem, aprendizado de máquina e inteligência artificial, a visão computacional pode oferecer algumas vantagens quando comparada ao processo tradicional relatado. Algoritmos de visão computacional são capazes de extrair características visuais únicas de plantas, como padrões de folhas, forma de flores e textura de caules. Através desses algoritmos, sistemas de visão computacional são treinados para identificar plantas com base em conjuntos de dados contendo imagens rotuladas (WÄLDCHEN; MÄDER, 2018). Quanto à limitação de escala, a utilização de dispositivos móveis e interfaces amigáveis, permite a identificação de plantas acessível mesmo para pessoas sem formação especializada em botânica (ALMEIDA et al., 2020).

A cana-de-açúcar é uma planta gramínea que é cultivada em todo o mundo, principalmente em regiões tropicais e subtropicais. Uma de suas características é a versatilidade; ela pode ser usada para a produção de diversos produtos, incluindo açúcar, etanol, biocombustíveis, papel, celulose e alimentos para animais. Segundo o Conab (2023), é uma das culturas mais importantes do Brasil, ocupando cerca de 14 milhões de hectares, representando cerca de 17% do valor total da produção agrícola brasileira. Estimativas para a safra 2023/24, apontam para uma produção de 40,8 milhões de toneladas de açúcar e 27,7 milhões de litros de etanol. Trata-se, portanto, de uma cultura muito importante para a economia brasileira, gerando empregos, renda e divisas para o país.

O universo dessa cultura é formado por diversas variedades, cada uma com características próprias. A escolha da variedade mais adequada para uma determinada região depende de diversos fatores, incluindo o clima, o solo e o sistema de cultivo. É importante plantar as variedades de acordo com seu ambiente de produção<sup>1</sup> para que assim possa apresentar maior produtividade, melhor qualidade e menor suscetibilidade a pragas e doenças (CURSI et al., 2022) (ALMEIDA et al., 2021). Uma vez plantada, a cana somente será identificada ou por um olhar atento de um especialista humano ou por meio de uma técnica chamada de identificação molecular por meio de uma análise de seu DNA (ALI et al., 2017).

Tendo em vista as limitações apresentadas à atividade de identificação de plantas por especialistas humanos e a análise de DNA depender de equipamento de laboratório especializado, pensou-se em uma solução de baixo custo, baseada em visão computacional, que tenha a capacidade de reconhecer a variedade, quando apresentada a uma imagem da cana. Neste sentido, foi realizada uma pesquisa na literatura especializada e constatado a existência de reconhecimento de espécies de plantas através de IA, porém não foram encontrados trabalhos direcionados à cultura de cana-de-açúcar. Na pesquisa mencionada foram encontrados diversos estudos correlatos que serviram de apoio a este projeto e que serão apresentados na seção 3 “Trabalhos Relacionados”. Dentre eles, dois trabalhos se destacaram em termos de corroborarem com a solução proposta. Em um deles, pesquisadores utilizaram a visão computacional para a identificação de espécies de bambu localizados na região nordeste da Índia (SARMA; TALUKDAR, 2020). Com base nesta pesquisa, surgiu uma das perguntas de

 pesquisa que este trabalho busca responder: “Se existe uma solução para a identificação de espécies de bambu, seria possível uma para identificação de variedades de cana-de-açúcar? Em outro trabalho, os autores apresentaram os resultados da classificação de 4 variedades de cana plantada em canaviais empregando técnicas de IA em imagens de satélite (MARQUES KAI; OLIVEIRA; COSTA, 2022). Esta pesquisa possibilitou a formulação de outra questão de

<sup>1</sup> Ambiente de produção é uma área dentro de uma propriedade rural que apresenta características relativamente homogêneas em termos de solo, relevo, clima e outros aspectos que influem no desenvolvimento e produtividade das culturas.

pesquisa: "Se existe uma solução capaz de reconhecer variedades de cana-de-açúcar utilizando imagens de satélite, e portanto com visão abrangente do canavial, seria possível o reconhecimento com imagens de campo, ao nível do solo, tendo uma visão individualizada da cana?"

Desta forma, estendendo os trabalhos de SARMA (2020) e KAI, OLIVEIRA & COSTA (2022), este projeto tem como objetivo investigar a viabilidade da utilização de Visão Computacional empregada à identificação de variedades de cana-de-açúcar utilizando imagens fotográficas. Por meio da análise de algoritmos avançados e da adaptação de técnicas de Visão Computacional para esse contexto específico, busca-se compreender a capacidade desses sistemas em acertar na identificação das variedades. Acredita-se que essa abordagem tecnológica inovadora poderá superar as limitações atuais do processo manual apresentado, permitindo uma identificação mais eficiente e inclusiva, não restrita à especialistas.



seu cresc

Conversar na reunião 26/09/23.

Objetivo (Já está poss)  
escolher o satélite de uso  
para ser usado nas telas  
de identificação dos tipos (fig)



A

(

o

o

o

mellorar  
ver  
com

Professor "sua" pg. está permanentemente no topo da lista, pode ser da ordem de leitura.

### 3. Trabalhos Relacionados

Nesta seção, serão apresentados os trabalhos que de alguma forma contribuíram com os objetivos desta pesquisa, sejam servindo como base ou corroborando com a proposta.

ALI et al. (2017) estabeleceram as identidades moleculares (ID) baseadas em marcadores de DNA SSR (microssatélite) para 91 variedades de cana-de-açúcar chinesas lançadas desde 2005. Além disso, os autores compararam dois métodos de detecção - eletroforese capilar (CE) e eletroforese em gel de poliacrilamida (PAGE), para avaliar a utilidade dessas abordagens na identificação de variedades e análise da diversidade genética da cana-de-açúcar. Esta maneira de identificar variedade, embora eficiente, é uma técnica invasiva e dispendiosa por exigir recursos laboratoriais.

(verificar com André se seria melhor desconsiderar artigo "antigo", pois abrange tecnologia até 2015.)

WÄLDCHEN & MÄDER (2018) realizaram uma revisão e analisaram de forma sistemática as pesquisas feitas no campo da identificação automatizada de espécies de plantas utilizando técnicas de visão computacional. A revisão focou principalmente em métodos tradicionais de visão computacional e processamento de imagens. As principais técnicas abordadas no artigo foram: os descritores de imagem para extração de características como forma, texto e cor (SIFT, SURF, histogramas, momentos, etc); classificadores como k-NN, SVM e redes neurais para reconhecimento de padrões; segmentação de imagem e extração de contornos; análise de textura e dimensão fractal e fusão de múltiplas características para melhoraria de desempenho. Algumas dessas técnicas, como redes neurais e SVM, fazem parte do campo da inteligência artificial, porém o artigo não chegou a discutir abordagens modernas de IA como aprendizado profundo ou redes neurais convolucionais. Provavelmente isso pode ter ocorrido devido a revisão sistemática ter focado em estudos publicados entre 2005 e 2015, antes do recente avanço e popularização das modernas técnicas de inteligência artificial. No entanto, embora contenha discussões limitadas sobre IA, o artigo fornece um bom mapeamento histórico de como os métodos de visão computacional eram aplicados para identificação de plantas baseada em imagens até meados da década passada.

PRABHU et al. (2021) forneceram uma perspectiva abrangente sobre o uso de técnicas de visão computacional para detecção de defeitos e doenças em frutas. Foi discutido o uso de vários modelos de machine learning tradicionais para a classificação de defeitos em frutas, que foram treinados com base nas características extraídas das imagens e são apresentados a seguir:

- SVM (Support Vector Machines): É o classificador mais amplamente utilizado e que tem se

# Termos estrangeiros em italiano



mostrado eficaz nesta aplicação de acordo com o artigo. O SVM cria um hiperplano otimizado para separar as classes.

- **KNN (K-Nearest Neighbors):** Classifica com base na distância para os k vizinhos mais próximos, requer menor treinamento mas é sensível a ruído.
- **Árvores de Decisão:** Segmentam os dados em regiões baseadas em condições if-then-else aplicadas às features, são fáceis de interpretar mas podem ocorrer overfit.
- **Redes Neurais Artificiais:** Modelos constituídos de camadas de neurônios interconectados, treinados via backpropagation, podem aprender representações complexas.
- **Florestas Aleatórias:** Ensemble de árvores de decisão treinadas em subconjuntos aleatórios dos dados, tende a ter bom desempenho.

O artigo não descreve em detalhes a arquitetura de um modelo específico de deep learning, mas aponta que as CNNs pré-treinadas estão sendo crescentemente utilizadas em trabalhos recentes sobre detecção de defeitos em frutas, superando resultados de métodos tradicionais em muitos casos. Mas não há discussão aprofundada sobre esses modelos de deep learning.

DEVI & GEETHA (2019) apresentaram uma extensa revisão bibliográfica de pesquisas recentes sobre a classificação de plantas, frutas e vegetais usando técnicas de deep learning, com foco em CNNs. A revisão cobre diversos conjuntos de dados de imagens do domínio agrícola e abordagens como Faster R-CNN, redes totalmente convolucionais, aprendizado por transferência, entre outros métodos baseados em CNNs. Os principais usos por tecnologia são destacados a seguir:

- **Faster R-CNN:** usado para detecção de frutas como maçãs, laranjas, mangas, etc. em ambientes naturais como pomares e estufas.
- **Redes totalmente convolucionais (FCN):** utilizadas para localização e contagem pixel-a-pixel de frutas agrupadas/sobrepostas como maçãs e laranjas.
- **Transfer learning:** modelo pré-treinado como GoogLeNet, AlexNet, VGGNet são ajustados para classificação de espécies de plantas usando conjuntos de dados como LeafSnap, Foliage, Flavia etc.
- **Redes neurais convolucionais (CNNs):** utilizadas para reconhecimento de folhas, detecção de ervas daninhas, segmentação de safras/solo, predição de rendimento e outras tarefas de visão computacional agrícola.
- **Modelos como ResNet:** alcançaram alta acurácia no conjunto de dados BJFU100 para classificação de 100 espécies ornamentais.
- **TensorFlow:** usado para classificar 60 tipos de frutas a partir do conjunto de dados Fruits-360.

O estudo apontou que as CNNs têm se mostrado uma tecnologia versátil e poderosa para ampliar a automação e análise de dados em várias tarefas no domínio agrícola. Sua capacidade

(É a 2<sup>a</sup>  
materia  
ao que  
o artigo  
NÃO FALA  
...)

Vale a pena dizer que é isso

de aprendizado de características a partir de dados permite excelentes resultados em problemas complexos de visão computacional.

ZOU et al. (2023) avaliaram um algoritmo de transformer de visão residual (ReVI) para a classificação de imagens de espécies de bambu. Especificamente, envolveram o algoritmo ReVI combinando mecanismos convolucionais e residuais com redes transformer de visão (ViT). Foi coletado e preparado um conjunto de dados com imagens de 19 espécies de bambu para avaliar o ReVI. As 19 espécies contaram com um total de 3220 imagens que foram coletadas e divididas em um conjunto de treinamento, um conjunto de validação e um conjunto de teste. Foi comparado o desempenho do ReVI com o ViT e outros modelos convolucionais (CNN) no conjunto de dados de bambu. O algoritmo ReVI proposto alcançou uma precisão média de 90,21% na classificação das espécies de bambu, superando os modelos ViT e CNNs como ResNet, VGG16 e DenseNet. O ReVI generalizou melhor que o ViT com quantidade limitada de dados de treinamento, mantendo uma precisão mais estável à medida que os dados de treinamento foram reduzidos. O ReVI também obteve desempenho superior ao ViT em métricas como recall, F1-score, especificidade e mAP (do inglês means Average Precision) no conjunto de dados de bambu. A análise das matrizes de confusão revelou que erros se concentraram em classes com poucas imagens, indicando que mais dados melhorariam o desempenho. As características convolucionais e residuais do ReVI permitiram extrair melhor as informações das imagens e generalizar em pequenos conjuntos de dados.

JUYAL et al. (2020) compararam diferentes algoritmos de aprendizado de máquina e aprendizado profundo para identificar e classificar 5 espécies comuns de bambu encontradas no norte da Índia. Os autores testaram algoritmos como Random Forest, Naive Bayes, SVM, Regressão Logística, Redes Neurais Convolucionais (CNN) e ResNet em um conjunto de dados de imagens coletadas do Instituto de Pesquisa Florestal em Dehradun com o objetivo de determinar qual abordagem teria a maior precisão na classificação das espécies de bambu. O algoritmo ResNet obteve a maior acurácia na classificação das 5 espécies de bambu, com 86% de acerto. Já o Naive Bayes apresentou o pior desempenho, com apenas 40% de acurácia. Outros algoritmos testados obtiveram acurácia intermediária: Random Forest 57%, SVM 60%, Regressão Logística 75% e Rede Neural Convolucional (CNN) 80%. Análises dos scores F1 para cada classe mostraram que o ResNet teve o melhor desempenho em todas as classes, em comparação aos outros algoritmos.

ALMEIDA et al. (2021) ressaltaram a importância de definir ambientes de produção na cultura da cana-de-açúcar para possibilitar o manejo localizado da lavoura, para orientar a aplicação diferenciada de insumos, manejo da cultura e expectativa de produtividade em cada talhão. No estudo, os ambientes de produção da cana foram determinados principalmente com base em atributos do solo como textura (teor de areia), classes de solo e suscetibilidade magnética. Cinco

ambientes de produção foram identificados na área de estudo utilizando a abordagem de aprendizado de máquina. O estudo enfatiza a importância do plantio correto de variedades de cana em seus respectivos ambientes de produção, contribuindo para alicerçar a importância da solução proposta.

VERMA et al. (2017) apresentaram um estudo sobre a classificação de imagens usando diferentes abordagens de árvores de decisão para identificar e discriminar a cultura de cana-de-açúcar em dados obtidos por sensoriamento remoto, mais especificamente, usando a imagem do satélite Indian Remote Sensing Satellite (IRS-P6) LISS IV, com uma resolução espacial de 5,8 metros, na vila de Chhapar, distrito de Muzaffarnagar, Índia. A classificação de dados de satélite é essencial para a extração de informações para a identificação de terras agrícolas e a identificação precisa e rápida da área cultivada é de extrema importância para projetar a produção agrícola anual e decidir políticas agrícolas. Os métodos de árvore de decisão baseados em índices de vegetação (ISODATA, MLC e outros) são comparados e o método de árvore de decisão com base em índices de vegetação mostrou o melhor desempenho na classificação da cultura de cana-de-açúcar. Além disso, o artigo apresenta os resultados da avaliação do método escolhido, mostrando as medidas de acurácia do usuário, acurácia do produtor, acurácia geral e coeficiente Kappa obtidos a partir da classificação da imagem da cultura de cana-de-açúcar diferenciando-as de outras culturas.

KAI, OLIVEIRA & COSTA (2022) propuseram um método baseado em redes neurais profundas para a classificação de variedades de cana-de-açúcar utilizando imagens de satélite Sentinel-2. Os autores desenvolveram uma rede neural densa juntamente com índices de vegetação e combinações de bandas RGB como entrada para discriminar entre quatro variedades de cana-de-açúcar. O método proposto é comparado com técnicas tradicionais de aprendizado de máquina como SVM e Random Forest. A abordagem de rede neural alcançou 99,48% de acurácia na discriminação das variedades. As principais descobertas indicam que as bandas Sentinel-2 relacionadas à clorofila são as mais úteis. A abordagem apresentada nesta pesquisa, embora possua como objetivo a identificação de variedades de cana, difere-se da nossa proposta devido à utilização do método. Enquanto KAI (2022) utiliza dados obtidos por sensoriamento remoto (imagens de satélite), nossa proposta é de obtenção de imagens através de dispositivos fotográficos comuns.

Faltou uma  
conclusão do capí-  
tulo, mas fizeram do  
porque faz sentido  
de a sua proposta

André

Conversar sobre a metodologia na próxima reunião.

Falta clareza, por isso não adianta escrever, fica muito genérico mesmo.

## 4. Metodologia

A metodologia utilizada nesta pesquisa contará com as seguintes etapas: determinar, através de estudos exploratórios, as ferramentas de Inteligência Artificial (IA) que serão utilizadas e suas respectivas configurações; das ferramentas selecionadas, identificar a que melhor se adeque ao reconhecimento dos padrões de imagens. Nesta etapa serão apresentadas às ferramentas, imagens de cana-de-açúcar obtidas na Internet a fim de determinar sua capacidade de reconhecimento; desenvolver um banco de imagens de duas variedades de cana-de-açúcar. Neste processo, será criado um protocolo indicando aspectos como, a câmera utilizada para captura de imagens, quantidade de imagens necessárias, qualidade da imagem, utilização de sensores, foco, iluminação, período do dia, ângulos de captura, entre outros. Ao final teremos, além do banco de imagens, todas as instruções para a condução de experimentos.

### 4.1. Recursos

Computador com placa GPU (Configuração...), câmera fotográfica (configuração...) Serão melhor estimadas quando o projeto estiver melhor delineado.

### 4.2. Métodos

Para conduzir esta pesquisa, serão utilizadas diferentes fontes de dados, incluindo literatura científica, publicações acadêmicas e relatórios técnicos listadas no portal de periódicos da CAPES. Operacionalmente, a pesquisa será organizada em etapas, apresentadas a seguir:

**Etapa 1 – Levantamento bibliográfico sobre o tema:** Realizar uma revisão de literatura científica com o objetivo de identificar as principais aplicações da visão computacional no reconhecimento e identificação de variedades de cana-de-açúcar. Considerar se existe similaridade deste processo para outras culturas agrícolas.

**Etapa 2 – Levantamento bibliográfico sobre algoritmos:** Realizar uma revisão de literatura científica para identificar os algoritmos de visão computacional mais utilizados e com melhores

resultados em reconhecimento de espécies de plantas, considerando critérios como acurácia, velocidade de processamento, eficiência computacional e facilidade de implementação.

*falta foto de foto*

*de foto*

*foto*

*com*

*misturado*

*de duas*

*previ*

*test*

*especificar*

**Etapa 3 - Criação de um banco de imagens:** Obter imagens genéricas de cana-de-açúcar em banco de dados da Internet. O objetivo neste primeiro momento é avaliar a capacidade do algoritmo selecionado em identificar cana-de-açúcar de outras culturas. Em um segundo momento, serão fotografadas, filmadas e rotuladas duas variedades da empresa parceira. Isto permitirá a construção de um banco de imagens, para que o algoritmo selecionado aprenda a reconhecer essas duas, das demais variedades existentes na base. A execução desta etapa possibilitará a criação de um estudo comparativo, capaz de responder às perguntas, como por exemplo, se é melhor capturar a imagem no nível do solo ou aérea, com alta ou baixa resolução, com ou sem flash, durante o dia ou à noite, utilizar infravermelho ou termografia? Para tanto, o processo será realizado in-loco (Estação experimental localizada em Maceió/Alagoas/Brasil).

**Etapa 4 - Instalação das ferramentas:** Instalação e configuração das ferramentas previstas para a utilização durante a pesquisa. Nesta etapa serão realizados os testes operacionais, desde a aquisição das imagens, até os resultados para a validação das ferramentas observadas na etapa 2.

**Etapa 5 - Seleção da ferramenta:** por meio de estudos exploratórios, determinar a capacidade de reconhecimento de padrões de cada algoritmo. Neste sentido, serão utilizados o banco de imagens e os algoritmos selecionados nas etapas anteriores. A fim de refinar o processo, será realizado um estudo a fim de verificar a interferência do fundo da imagem no processo de reconhecimento de padrões, através de testes em imagem original versus imagens com remoção do fundo.

**A partir aqui, conversar com André para decidir a parte técnica dos experimentos**

#### 4.3. Parcerias de pesquisa e institucionais

A cooperação proposta entre a Instituição Pública UNICAMP e a empresa privada GRANBIO tem como objetivo identificar ou mesmo criar uma metodologia que seja capaz de diferenciar e identificar variedades de cana VERTIX (marca registrada).

A sinergia entre Universidade e Empresa poderá colher bons frutos futuramente, como os destacados a seguir:

- Caso a metodologia seja capaz de diferenciar as duas variedades, isso pode se transformar em uma patente.
- A tese pode se transformar em um grande projeto. Futuramente, poderá identificar todas as

11 variedades VERTIX e variedades de outros Institutos, como IAC, CTC, EMBRAPA, entre outros. *e.c.*

#### 4.4. Recursos Financeiros

Esta pesquisa deve contar, caso seja estabelecida a parceria, com apoio técnico e financeiro da Empresa. Estimativas iniciais são destacadas no quadro a seguir:

Item	Valor
Viagem	R\$ 8.000,00 (R\$2.000,00 x 4 visitas)
Hospedagem	R\$ 2.400,00 (R\$600,00 x 4 visitas)
Drone	R\$ 5.000,00
Câmera	R\$ 15.000,00
Equipamento para rodar a rede	R\$ 9.600,00 (notebook ou nuvem)
<b>Valor de referência</b>	<b>R\$ 100.000,00</b>

#### 4.5. Indicadores de Desempenho

*incluir medidas ressalta de ANO,*  
*(será estabelecido posteriormente..) Conversar com André para identificar os Indicadores de desempenho*

#### 4.6. Propriedade Intelectual

Devido às características deste tipo de pesquisa. É desejável identificar possíveis conflitos de interesse. Para tanto, os itens a seguir podem atuar a fim de minimizar tais conflitos:

- Estabelecer um acordo claro de propriedade intelectual e dos resultados da pesquisa.
- Definir quem terá o direito de publicar os resultados da pesquisa.
- Garantir que a pesquisa seja realizada de forma imparcial e que os interesses da empresa não comprometam a qualidade da pesquisa

#### 4.7. Riscos e Contingências

*→ finalizar a seção*

O projeto acarreta riscos inerentes à uma pesquisa inédita no reconhecimento de variedades de cana-de-açúcar. Neste sentido, foram elencados possíveis riscos e suas respectivas contingências, listadas a seguir:

- Risco 1: A pesquisa corre um alto risco, caso apareça uma publicação que trate do mesmo problema e solução proposta, abordados neste projeto, ocasionando a perda de seu ineditismo. A contingência adotada seria: *(conversar com André a respeito. Este risco é muito alto!!! Chineses e Indianos...)*
  - *André, tem um artigo que trata de reconhecimento de variedades, mas a proposta é outra. O reconhecimento se dá por talhão e através de imagens de satélite.*
- Risco 2: Risco de a pesquisa não revelar resultados significativos, que indiquem que as

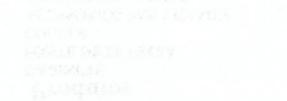
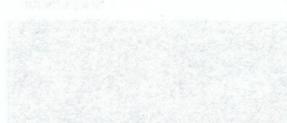
ferramentas e técnicas utilizadas foram capazes de diferenciar variedades de cana-de-açúcar. Caso se incorra nesta condição em qualquer uma das fases do trabalho, o plano de contingência é:

- Determinar os fatores que levaram aos resultados inconclusivos;
- Para os fatores controláveis, eliminá-los e refazer os experimentos;
- Para os fatores incontroláveis, investigar formas de contorno e refazer os experimentos.

Caso ainda não seja possível obter resultados satisfatórios, então:

- Determinar se é possível concluir que o método é inviável para a aplicação sob análise, encerrando com sucesso a pesquisa, ou propor estratégias de adaptação do método que possam embasar futuras investigações, encerrando com sucesso a pesquisa

Pensando em uma forma de acompanhar o projeto e seus riscos, decidiu-se por utilizar o critério “*Go/Nogo*” em todas as fases do projeto. Desta forma, tem-se a chance de abandonar o projeto, ou adotar outras medidas de contingência. Os riscos e possíveis contingências serão identificados ao longo de todo o projeto, à medida que avançamos nas fases.



## 6. Cronograma\*

Segue-se o cronograma semestral proposto para este projeto de pesquisa, incluindo o Exame de Qualificação e a Defesa da Tese.

Fase/Atividade	Semestres	2023		2024	
		2º	1º	2º	3º
Acompanhamento da literatura		X		X	
Seleção e configuração da IA		X			
Identificação e aquisição dos equipamentos necessários à pesquisa		X			
Exame de Qualificação				X	
Desenvolvimento da metodologia de captação de imagens				X	X
Desenvolvimento do experimento de reconhecimento de 2 variedades				X	
Análise dos resultados					X
Defesa da Tese					X

\* conversar a possibilidade de antecipar ao máximo a conclusão do Doutorado!

Assinatura do autor:

DATA: 01/06/2024

Assinatura do orientador:

DATA: 01/06/2024

Assinatura do coorientador:

DATA: 01/06/2024

Assinatura do supervisor:

DATA: 01/06/2024

Assinatura do conselheiro:

DATA: 01/06/2024

E-mail: [professor@ufsc.br](mailto:professor@ufsc.br)  
Fone: (48) 3302-3353 | (48) 30-3392-4054



## 7. Referências Bibliográficas

- ALI, A. et al. Molecular Identification and Genetic Diversity Analysis of Chinese Sugarcane (*Saccharum* spp. Hybrids) Varieties using SSR Markers. **Tropical Plant Biology**, v. 10, n. 4, p. 194–203, 1 dez. 2017.
- ALMEIDA, B. K. et al. Not that kind of tree: Assessing the potential for decision tree-based plant identification using trait databases. **Applications in Plant Sciences**, v. 8, n. 7, p. e11379, jul. 2020.
- ALMEIDA, G. M. DE et al. Machine learning in the prediction of sugarcane production environments. **Computers and Electronics in Agriculture**, v. 190, p. 106452, 1 nov. 2021.
- BONNET, P. et al. Plant identification: man vs. machine. **Multimedia Tools and Applications**, v. 75, n. 3, p. 1647–1665, 1 fev. 2016.
- Conab - Safra Brasileira de Cana-de-açúcar**. Disponível em: <<https://www.conab.gov.br/info-agro/safras/cana>>. Acesso em: 17 ago. 2023.
- CURSI, D. E. et al. History and Current Status of Sugarcane Breeding, Germplasm Development and Molecular Genetics in Brazil. **Sugar Tech**, v. 24, n. 1, p. 112–133, 1 fev. 2022.
- DEVI S, S.; GEETHA, A. Fruits, Vegetable and Plants Category Recognition Systems Using Convolutional Neural Networks : A Review. **International Journal of Scientific Research in Computer Science, Engineering and Information Technology**, p. 452–461, 15 jun. 2019.
- HEMALATHA, N. K. et al. Chapter 12 - Sugarcane leaf disease detection through deep learning. Em: POONIA, R. C.; SINGH, V.; NAYAK, S. R. (Eds.). **Deep Learning for Sustainable Agriculture. Cognitive Data Science in Sustainable Computing**. [s.l.] Academic Press, 2022. p. 297–323.
- JUYAL\*, P. et al. Common Bamboo Species Identification using Machine Learning and Deep Learning Algorithms. **International Journal of Innovative Technology and Exploring Engineering**, v. 9, n. 4, p. 3012–3017, 28 fev. 2020.
- KUMPALA, I.; WICHAPHA, N.; PRASOMSAB, P. Sugar Cane Red Stripe Disease Detection using YOLO CNN of Deep Learning Technique: doi: 10.14456/mijet.2022.25. **Engineering Access**, v. 8, n. 2, p. 192–197, 2 abr. 2022.
- MARQUES KAI, P.; OLIVEIRA, B.; COSTA, R. Deep Learning-Based Method for Classification of Sugarcane Varieties. **Agronomy**, v. 12, p. 2722, 2 nov. 2022.
- MILITANTE, S. V.; GERARDO, B. D.; DIONISIO, N. V. **Plant Leaf Detection and Disease Recognition using Deep Learning**. 2019 IEEE Eurasia Conference on IOT, Communication and Engineering (ECICE). **Anais...** Em: 2019 IEEE EURASIA CONFERENCE ON IOT, COMMUNICATION AND ENGINEERING (ECICE). out. 2019.
- MILITANTE, S. V.; GERARDO, B. D.; MEDINA, R. P. **Sugarcane Disease Recognition using Deep Learning**. 2019 IEEE Eurasia Conference on IOT, Communication and Engineering (ECICE). **Anais...** Em: 2019 IEEE EURASIA CONFERENCE ON IOT, COMMUNICATION AND ENGINEERING (ECICE). out. 2019.
- ORDINE PIRES DA SILVA SIMÕES, I. et al. Recognition of sugarcane orange and brown rust through leaf image processing. **Smart Agricultural Technology**, v. 4, p. 100185, 1 ago. 2023.

PRABHU, A. et al. **Applications of Computer Vision for Defect Detection in Fruits: A Review**. 2021 International Conference on Intelligent Technologies (CONIT). *Anais...* Em: 2021 INTERNATIONAL CONFERENCE ON INTELLIGENT TECHNOLOGIES (CONIT). jun. 2021.

SARMA, P.; TALUKDAR, J. K. **Digital Image Processing based proposed approach to Identify Different Bamboo Species**. 2020 Second International Conference on Inventive Research in Computing Applications (ICIRCA). *Anais...* Em: 2020 SECOND INTERNATIONAL CONFERENCE ON INVENTIVE RESEARCH IN COMPUTING APPLICATIONS (ICIRCA). jul. 2020.

VERMA, A. K.; GARG, P. K.; HARI PRASAD, K. S. Sugarcane crop identification from LISS IV data using ISODATA, MLC, and indices based decision tree approach. *Arabian Journal of Geosciences*, v. 10, n. 1, p. 16, 3 jan. 2017.

WÄLDCHEN, J. et al. Automated plant species identification—Trends and future directions. *PLOS Computational Biology*, v. 14, n. 4, p. e1005993, 5 abr. 2018.

WÄLDCHEN, J.; MÄDER, P. Plant Species Identification Using Computer Vision Techniques: A Systematic Literature Review. *Archives of Computational Methods in Engineering*, v. 25, n. 2, p. 507–543, 1 abr. 2018.

ZHAO, C. et al. Plant identification using leaf shapes—A pattern counting approach. *Pattern Recognition, Discriminative Feature Learning from Big Data for Visual Recognition*. v. 48, n. 10, p. 3203–3215, 1 out. 2015.

ZOU, Q. et al. An Improved Vision Transformer Network with a Residual Convolution Block for Bamboo Resource Image Identification. *Electronics*, v. 12, n. 4, p. 1055, 20 fev. 2023.